

Part A: theory cap

1. Term frequency: $tf(t, d) = \frac{c(t, d)}{\sum_{t'} c(t', d)}$

với $c(t, d)$: số lần term(t) xuất hiện trong document(d)
mẫu số là tổng term trong document.

2. Document frequency

$$df(t) = |\{d: t \in d\}| : \text{số document chứa term}(t)$$

3. Inverse Document frequency

$$idf(t) = \log \frac{N}{df(t)}, \quad N: \text{tổng số document.}$$

Biến thể smoothing: $idf(t) = \log \frac{1 + N}{1 + df(t)} + 1$

4. TF-IDF.

$$tf-idf(t, d) = tf(t, d) \times idf(t)$$

Một term quan trọng đối với document nếu nó xuất hiện nhiều trong document đó nhưng không xuất hiện quá phổ biến trong toàn corpus.

5. Cosine similarity: đo độ giống nhau về hướng của 2 vector.

$$\cos(x, y) = \frac{x^T y}{\|x\|_2 \|y\|_2}$$

Part B: Calculation exercise

Exercise 1:

D_1 : "cat eats fish"

D_3 : "cat likes fish"

D_2 : "dog eats fish"

Vocabulary = {cat, dog, eats, fish, likes}

Count vector:

$D_1 = (1, 0, 1, 1, 0)$

$D_3 = (1, 0, 0, 1, 1)$

$D_2 = (0, 1, 1, 1, 0)$

Memo No. _____

Date / /

Exercise 2: TF

$$t_f(\text{cat}, D1) = \frac{c(t, d)}{\sum_{t'} c(t', d)} = \frac{1}{3}$$

$$t_f(\text{eats}, D1) = \frac{c(t, d)}{\sum_{t'} c(t', d)} = \frac{1}{3}$$

$$t_f(\text{fish}, D1) = \frac{c(t, d)}{\sum_{t'} c(t', d)} = \frac{1}{3}$$

$$\sum_t t_f(t, D1) = \frac{1}{3} + \frac{1}{3} + \frac{1}{3} = 1$$

Exercise 3: IDF

Corpus có $N = 3$ và $d_f(\text{cat}) = 2$; $d_f(\text{dog}) = 1$, $d_f(\text{eats}) = 2$
 $d_f(\text{fish}) = 3$, $d_f(\text{likes}) = 1$

$$idf(\text{cat}) = \log \frac{N}{d_f(\text{cat})} = \log \frac{3}{2} = \log 1.5 \approx 0.4055$$

$$idf(\text{dog}) = \log \frac{N}{d_f(\text{dog})} = \log \frac{3}{1} = \log 3 \approx 1.0986$$

$$idf(\text{eats}) = \log \frac{N}{d_f(\text{eats})} = \log \frac{3}{2} \approx 1.0986 \text{ } 0.4055$$

$$idf(\text{fish}) = \log \frac{N}{d_f(\text{fish})} = \log \frac{3}{3} = \log 1 = 0$$

$$idf(\text{likes}) = \log \frac{3}{d_f(\text{likes})} = \log 3 \approx 1.0986$$

Term fish có IDF thấp nhất vì term "fish" xuất hiện ở cả 3 document cho thấy độ hiếm của term trên toàn bộ corpus không cao nên chỉ số IDF của term khi đưa vào công thức $\log \frac{N}{d_f(t)}$ thì được thấp.

Exercise 4: TF-IDF

$D1 = \text{"cat eats fish"}$

$$tf-idf(cat) = tf(cat) \cdot idf(cat) = \frac{1}{3} \cdot \log 1.5 = 0.1352$$

$$tf-idf(eats) = tf(eats) \cdot idf(eats) = \frac{1}{3} \cdot \log 1.5 = 0.1352$$

$$tf-idf(fish) = tf(fish) \cdot idf(fish) = \frac{1}{3} \cdot 0 = 0$$

Fish xuất hiện trong mọi document nhưng $tf-idf$ của nó bằng 0 do chỉ số đo độ hiếm idf được tính theo công thức $\log \frac{N}{df(t)}$ với N là số văn bản và $df(t)$ là tần số văn bản chứa từ t do nên với mọi từ học thì văn bản nào cũng chứa từ fish nên khiến cho biểu thức $\log \frac{N}{df(t)}$ trở về giá trị 0 dẫn tới kết quả khi thực hiện nhân hai chỉ số $tf(t)$ và $idf(t)$ cho kết quả bằng 0. Vì một lý do tương tự nên giá trị của chỉ số

Exercise 5: Cosine similarity.

$$x = [1, 1, 1] \quad y = [1, 1, 0]$$

$$\cos(x, y) = \frac{x^T \cdot y}{\|x\| \|y\|} = \frac{1 \cdot 1 + 1 \cdot 1 + 1 \cdot 0}{\sqrt{1^2 + 1^2 + 1^2} \cdot \sqrt{1^2 + 1^2 + 0^2}} = \frac{2}{\sqrt{3} \cdot \sqrt{2}} = \frac{2}{\sqrt{6}}$$

Hai document có hai term giống nhau trên 3 term tổng cộng, nhưng cosine similarity không bằng $(\frac{2}{3})$ vì hai vectơ ở đây không phải là hai vectơ đơn vị nên cosine tính góc giữa 2 vectơ.

Exercise 6

1. Document D1 = "medical image classification"

D2 = "medical image analysis"

D3 = "natural language processing"

Q = "medical image classification"

1. Document D1 có similarity cao nhất

2. Document D3 có similarity thấp nhất

3. Term "medical" và "image" có thể có giá trị IDF thấp nhất

Memo No. _____

Date / /

4. nếu bỏ IDF và chỉ sử dụng count vector thì ranking không thay đổi