

VD: the cat, the dog, the fish

Nếu $c(\text{the cat}) = 20$, $c(\text{the}) = 100$, $\Rightarrow P(\text{cat}|\text{the}) =$

$$P(\text{cat}|\text{the}) = \frac{c(\text{the cat})}{c(\text{the})} = \frac{20}{100} = 0,2$$

c) Trigram

Trigram sử dụng 2 từ trước $P(w_t | w_{t-2}, w_{t-1})$

$$\text{Ước lượng } P(w_t | w_{t-2}, w_{t-1}) = \frac{c(w_{t-2}, w_{t-1}, w_t)}{c(w_{t-2}, w_{t-1})}$$

4. Bài tập tính toán

Bài 1: Unigram

Cho corpus: "the cat eats fish"

"the cat likes fish"

"the dog eats meat"

1) Vocabulary: $V = \{\text{'the', 'cat', 'eats', 'fish', 'likes', 'dog', 'meats'}\}$

2) Tổng số tokens = $4 + 4 + 4 = 12$

3. Tính $P(w)$ cho

$$P(\text{the}) = \frac{c(\text{the})}{N} = \frac{3}{12} = \frac{1}{4} = 0,25$$

$$P(\text{cat}) = \frac{c(\text{cat})}{N} = \frac{2}{12} = \frac{1}{6} \approx 0,166$$

$$P(\text{fish}) = \frac{c(\text{fish})}{N} = \frac{2}{12} = \frac{1}{6} \approx 0,166$$

$$P(\text{dog}) = \frac{c(\text{dog})}{N} = \frac{1}{12} \approx 0,0833$$

$$\sum_w P(w) = \frac{3}{12} + \frac{2}{12} + \frac{2}{12} + \frac{1}{12} + \frac{1}{6} + \frac{1}{12} + \frac{1}{12} = 1$$

$$P(\text{eats}) = \frac{c(\text{eats})}{N} = \frac{2}{12} = \frac{1}{6} \approx 0,166$$

$$P(\text{likes}) = \frac{c(\text{likes})}{N} = \frac{1}{12} \approx 0,0833$$

$$P(\text{meats}) = \frac{c(\text{meats})}{N} = \frac{1}{12} \approx 0,0833$$

Bài 2. Bigram

$$P(\text{cat} | \text{the}) = \frac{C(\text{the cat})}{C(\text{the})} = \frac{2}{3} = 0,667$$

$$P(\text{dog} | \text{the}) = \frac{C(\text{the dog})}{C(\text{the})} = \frac{1}{3} = 0,33$$

$$P(\text{eats} | \text{cat}) = \frac{C(\text{cat eats})}{C(\text{cat})} = \frac{1}{2} = 0,5$$

$$P(\text{likes} | \text{cat}) = \frac{C(\text{cat likes})}{C(\text{cat})} = \frac{1}{2} = 0,5$$

Tổng xác suất của các từ đứng sau the phải bằng 1 nếu vocabulary và context đã xử lý đầy đủ vì khi đã xác định context thì từ tiếp theo sẽ phải nằm trong vocabulary. Thế nên nên đầy đủ thì tất cả các khả năng của từ tiếp theo đều được hết nên tổng xác suất của chúng = 1.

Bài 3. Xác suất cao

cho corpus "the cat eats fish"

$$P(\text{the cat eats fish}) = P(\text{the}) \cdot P(\text{cat} | \text{the}) \cdot P(\text{eats} | \text{cat}) \cdot P(\text{fish} | \text{eats}) \\ = \frac{1}{4} \cdot 1 \cdot 1 \cdot 1 = 0,25$$

Nếu thêm một từ vào câu, xác suất của cả câu ko nhất thiết phải tăng vì việc thêm từ sẽ làm thay đổi xác suất n-grams đặc biệt là xác suất liên quan đến từ đã thêm vào.

Bài 4. Sentences ranking

$S_1 = \text{the cat eats fish}$

$S_2 = \text{the dog eats fish}$

Dựa vào corpus thì có thể thấy câu S_1 sẽ có xác suất cao hơn.

$$P(S_1) = P(\text{the}) \cdot P(\text{cat} | \text{the}) \cdot P(\text{eats} | \text{cat}) \cdot P(\text{fish} | \text{eats}) = \frac{1}{4}$$

$$P(S_2) = P(\text{the}) \cdot P(\text{dog} | \text{the}) \cdot P(\text{eats} | \text{dog}) \cdot P(\text{fish} | \text{eats}) = \frac{1}{4} \cdot 0 \cdot 0 \cdot 1 = 0$$

5 Zero probability.

Xét the cat eats fish

Nếu corpus không chứa "cat eats" thì $c(\text{cat eats}) = 0$. Do đó,
 $P(\text{eats} | \text{cat}) = 0$. Khi tính xác suất của câu của $P(S) = \prod_t P(w_t | w_{t-1}) = 0$
 $\Rightarrow$ zero-frequency problem

6 Bài tập predict từ khi smoothing

corpus = ["I like NLP", "I like AI", "I study NLP"]

$P(\text{AI} | \text{study}) = ?$

1. $c(\text{study}) = 1$, $c(\text{AI}) = 1$, $c(\text{study AI}) = 0$

2. Xác suất MLE = $\frac{c(\text{study, AI})}{c(\text{study})} = 0$

3. Khi tính xác suất của câu chứa bigram này thì sẽ trở về kết quả bằng 0 khi bài tập không có cụm "study AI" trong corpus

4. Điều này không có nghĩa là mô hình "biết" rằng câu đó chưa chắc họ sẽ xảy ra bởi vì ở thời điểm mô hình chưa được thấy cụm đó nên nó khi nó áp dụng MLE nó dựa vào count nên kết quả cho thấy là họ tìm thấy cụm nào như vậy là đúng. Chưa trên thực tế nó cụm này vẫn có thể xảy ra

7. Smoothing.

a) Add-one / Laplace smoothing

$$P_{\text{Laplace}}(w|h) = \frac{c(h, w) + 1}{c(h) + V} \quad (h): \text{context}$$

(V) = vocabulary size

Smoothing làm thay đổi toàn bộ phân phối xác suất

VD $c(\text{cat}) = 10$, $c(\text{cat eats}) = 0$, $V = 5$

$$P_{\text{Laplace}}(\text{eats} | \text{cat}) = \frac{c(\text{cat eats}) + 1}{c(\text{cat}) + 5} = \frac{1}{10 + 5} = 0,1$$

Memo No. _____

Date / /

$$P(\text{eats} | \text{cat}) = \frac{3+1}{5+5} = 0,4$$

Smoothing đã thay đổi các bigram khác là nó đã tạo ra được giảm sự chênh lệch xác suất giữa bigram & xuất hiện nhiều & xuất hiện ít.