

Learning is the eye of the mind

lhtuy@gmail.com



trình bày nội dung về đề tài đbg (23-30/9)
Cài load ảnh.

Error analysis

Reflection - Từ word2Vec đến Transformer

Representation	Context - dependent?	Sparse/Dense	1 từ có n-vt.
TF-IDF	không	Sparse	không
Co-occurrence	dùng đề dìm	Sparse	không
word2Vec	không	Dense	không
Contextual embeddings	có	Dense	có

Error analysis

3 similarity đúng

doctor → surgeon, dentist, ophthalmologist, physician, veterinarian

Observed: top-5 từ similarity to doctor: surgeon(0,741), dentist(0,711), ophthalmologist(0,696), physician(0,689), veterinarian(0,675) - toàn bộ là thuộc ngữ ngành y.

Expected: các từ chỉ người làm trong nghề y,

possible explanation: các từ này có ngữ cảnh giống nhau nên ship-grams học dc verb gần nhau. Chúng gần nhau và thay thế dc cho nhau trong cùng 1 kiểu câu

Evidence from corpus:

top context of doctor: eye, should, talk, care, health,...

surgeon: lasik, eye, you're, should, ask,...

Tần suất từ lớn để học: doctor = 263, surgeon = 117, physician = 86, dentist = 49.

disease → infection, chronic, autoimmune, hypertension, artery

Observed: top-5 của disease là infection(0,760), chronic(0,760)

Gemma

Learning is the eye of the mind



Cutoimmune (0,750), hypertension (0,748), artery (0,746)

+ Expected: các từ về bệnh tật.

- Possible explanation: "disease" xuất hiện trong ngữ cảnh y khoa nhất quán nên vector của nó nằm trong cụm từ y khoa.

- Evidence from corpus:

- top context of disease: heart, risk, disease, patient, control, Lyme, chronic, cause,...

- top context of autoimmune: diseases, disorder, disease, immune, disease, chronic,...

* Tần suất: disease = 368 lần, infection = 94 lần

• Similarity sai.

- football → replica, shirt, shirts, thecheap, shirts.

+ Observed: top-5 của football là replica (0,885), shirt (0,832), shirts (0,798), thecheap (0,734), shirts (0,680) - toàn đó bóng đá và từ rẻ.

+ Expected: soccer, match, team, player, league.

- Possible explanation: noisy data + domain bias. Một số trong spam SEO bán áo bóng đá giá rẻ lặp lại "cheap football shirts" hàng trăm lần, chiếm phần lớn số lần football xuất hiện, nên vector của football bị kéo về phía đó.

+ Evidence from corpus: 573 lần trong 113 documents nhưng chỉ 4 document spam (chứa replica/thecheap) chiếm 348 lần.

- banana → sprouts, beef, smoothie, almond, chilli

- Observed: top 5 của banana là sprout (0,706), beef (0,704), smoothie (0,697), chilli (0,690) - nguyên liệu nấu ăn.

+ Expected: apple, mango, fruit, orange.

- Possible explanation: Frequency: banana chỉ xuất hiện 4 lần và các từ rất gần còn ~~low~~ hiếm. Domain: banana trong web

Gemma

Learning is the eye of the mind



Text thường nằm trong ngữ cảnh đồ ăn (banana bread, chocolate banana, công thức xay sinh tố) chứ không phải trong ngữ cảnh các loại quả, nên cả cụm laný quáng đều là đồ ăn

• Evidence from corpus:

• Top context (banana): festivals, export, bread, pulp, board, programme, pan, green

• ngữ cảnh chung gần như không có: banana-sprouts; không có, banana-chilli: không có; banana smoothie: chỉ "green", banana-almond: chỉ cake.

- không có câu nào chứa cả banana và sprout / smoothie / chilli.
Có duy nhất 1 câu có banana và almond: "put all ingredients in the blender starting with the banana add fruit then the almond butter on top"