Reflection

1. Đối chiếu Predictions với kết quả thực nghiệm.

Prediction 1: Key có score lớn nhất nhận weight lớn nhất.

Kết quả thực tế: Với scores [1,2,3], weights = [0,090; ~~[illegible]~~ 0,245; 0,665]

=> Dự đoán phù hợp: weight lớn nhất là 0,665, chưa phải toàn bộ weight.

Prediction 2: Score [1, 1, 1, 1] phân bố đều nhau,

Kết quả thực tế: weights = [0,25; 0,25; 0,25; 0,25]

HẢI TIẾN

=> Dự đoán đúng. Query ko ưu tiên key nào theo score đã cho, entropy = ln(4)

Prediction 3: Score [1, 1, 1, 10] làm attention tập trung ở token thứ ba

Kết quả thực tế: weights ≈ [0,00012338; 0,00012338; 0,99975324]

=> Dự đoán đúng: Token thứ 3 nhận khoảng 99,9753%

Prediction 4: Tăng 10 - 1000 token làm ma trận self-attention tăng 10 000 lần

=> ~~Dự đoán đúng~~: Kết quả thực tế: số phần tử tăng 1 000 000, median forward CPU tăng khoảng 0,0317 → 2,8869 ms.

- Dự đoán chưa hoàn toàn chính xác: runtime tăng khoảng 91,07 lần trong benmark này, ko phải 10 000 lần vì overhead và hiệu suất phép ma trận.

Prediction 5: Attention ko luôn trùng từ quan trọng theo con người

Kết quả thực tế: câu c1 trong các case lỗi đặt weight cao ở masterpiece chỉ lời khen hướng tới bản phim ≠; c2 nhấn horrible trong "not a lot of horrible"; câu "I like this movie" nhấn I.

=> Dự đoán khá tốt với các ví dụ quan sát được. Heatmap chưa đủ cm nguyên nhân lỗi; permutation trong c1, c2 cung cấp thêm bằng chứng về độ nhạy của model.

2. Scaling và temperature thay đổi cái gì?

Với scores [4, 2, 0], chia căn $d_k = 4$ cho [2, 1, 0]. Max weight giảm 0,867 → 0,665; entropy tăng 0,442 → 0,832. Thứ tự ưu tiên giữ nguyên nhưng distribution ít nhọn hơn.

Khi đổi query sentiment sang topic và giữ K, V, token nhận weight lớn nhất đổi từ good sang movie. Đây là ví dụ giả lập để thấy attention phụ ∈ query, không phải là 1 danh sách từ quan trọng cố định cho cả câu. Các tên sentiment/topic do người làm quy ước hai trục độ, ko phải ngữ nghĩa tự xuất hiện từ training

3. Các kết quả bất ngờ

3.1. Attention cao có thể hỗ trợ mô hypothesis nhưng ko giải thích toàn bộ model.

Trong E_1, thay masterpiece ở vị trí 56 = UNK làm Positive giảm từ 0,8003 → 0,4337; đổi dự đoán thành negative. Trong E_2, thay horrible ở vị trí 61 làm Positive tăng 0,4378 - 0,8260; đổi thành Positive. Thay vị trí weight thấp chỉ thay đổi khoảng -0,0108 và -0,03 tương ứng ko đổi nhãn.

3.2. Attention pattern ko tự là linguistic explanation.

Top 3 keys:

Query	key 1st	key 2nd	key 3rd
cat	adopted: 0,254	that: 0,150	sleeping: 0,144
adopted	adopted: 0,224	that: 0,204	sleeping: 0,180
sleeping	adopted: 0,202	that: 0,189	sleeping: 0,173.

Các hàng có phân phối ≠ nhau vì mỗi token tạo query ≠ nhau cùng 1 sequence ko có 1 danh sách attention duy nhất cho mọi query

Heatmap ko chứng minh model hiểu ngữ pháp. Đây là kết quả của vecto ngẫu nhiên và phép nhân ma trận, ko phải là mô hình đã học từ dữ liệu ngôn ngữ. Nếu 1 ~~ngữ~~ hiểu hết liên cơ hợp nghĩa câu thì cũng chưa có bằng chứng hiểu ngữ pháp. Thay seed hoặc embedding có thể đổi pattern. ~~Attention~~ từ ~~classifier đã huấn luyện~~ ~~đc~~ xem riêng ở Application và ~~error~~ an