PREDICTION.

PREDICTION 1: Mọi transformer có thể xử lý các token trong sequence song song hơn RNN không?

Prediction: Có

Reason: Trong transformer, cơ chế self-attention cho phép các token trong sequence tương tác trực tiếp với nhau. Các phép tính attention có thể được thực hiện đồng thời cho mọi vị trí token. Trong khi đó, RNN phải xử lý qua tuần tự từng timestep, sử dụng hidden state bước trước để tính bước tiếp theo.

Confidence: 80%

Prediction 2: Nếu bỏ positional encoding, transformer có còn biết thứ tự token không?

Prediction: Không

Reason: Self-attention tự thân không chứa thông tin về vị trí của token trong sequence. Positional encoding được cộng vào embedding để cung cấp thông tin vị trí. Nếu loại bỏ thành phần này, transformer không có thông tin tường minh để xác định token nào đứng trước token nào đứng sau token ?.

- Confident: 80%

Prediction 3: nếu hai câu có cùng tập token nhưng ≠ thứ tự, transformer không có positional information có thể phân biệt chúng không?

Prediction: không thể phân biệt đúng tin cậy về mặt thứ tự

HẢI TIẾN

Memo No.
Date / /

- Reason: khi ko có Positional encoding, self-attention ko sử dụng vị trí của token để xác định quan hệ giữa chúng. Vì vậy, hai sequence có cùng tập token nhưng ≠ thứ tự có thể tạo ra cùng 1 representation sau khi tổng hợp theo cách ko phụ ∈ thứ tự; chẳng hạn mean pooling. Tuy nhiên, representation tại từng vị trí vẫn có thể đc hoán đổi tương ứng vs thứ tự đầu vào.
- Confidence: 80%

+ Prediction 4: Hai attention heads có chắc chắn luôn học cùng 1 attention pattern ko? nhất thiết accuracy tăng ko?
Prediction: không.
Reason: Mỗi attention head có các projection matrices riêng cho Query, key, value. Vì vậy, các heads có khả năng học ra cách biểu diễn và mqh giữa các token. Tuy nhiên, ko đảm bảo rằng chúng luôn học đc các attention patterns ≠ nhau; một số heads vẫn có thể tạo ra pattern tương tự nhau.
- Confidence: 90%.

Prediction 5: Tăng số attention head có chắc chắn luôn tăng accuracy ko?
- Prediction: ko
- Reason: Tăng số attention heads cho phép mô hình thực hiện ra phép chiếu attention song song hơn. Tuy nhiên, khi dmodel cố định, vc tăng số heads làm giảm dimension của mỗi head. Điều này ko đảm bảo mô hình có representation tốt hơn. Ngoài ra, accuracy còn phụ ∈ vào dữ liệu, kiến trúc, training và các hyperparameter ≠.
- Confidence: 80%

Prediction 6: Transformer có luôn nhanh hơn RNN trên mọi sequence length ko?
+ Prediction: ko
+ Reason: Transformer có thể xử lý song song các token, nhưng self-attention có computational cost vd bậc nhất tăng theo (sequence length)$^2$. RNN có thể xử lý tuần tự vs computational cost tăng tuyến tính theo độ dài sequence.

HẢI TIẾN